

Des définitions, du vocabulaire et des exemples

Café des Sciences

Quentin Giton

6 Juin 2026

Plan

- 👉 Algorithmes
- 👉 Apprentissage Machine (ML)
 - ➡ La régression linéaire
 - ➡ L'importance du nombre de données
 - ➡ L'importance du nombre de paramètres
- 👉 Réseaux de neurones
 - ➡ Choix de la fonction de perte
- 👉 Modèles Génératifs
- 👉 Grands Modèles de Langage (LLM)
- 👉 Pour résumer

Algorithmes

Exemple 1

- ▶ Choisir trois nombres
 x_1, x_2, x_3
- ▶ Multiplier :
 - ▶ x_1 par 2
 - ▶ x_2 par 1
 - ▶ x_3 par 5
- ▶ Ajouter le tout
- ▶ Retrancher 10

Algorithmes



Exemple 1

- ▶ Choisir trois nombres x_1, x_2, x_3
- ▶ Multiplier :
 - ▶ x_1 par 2
 - ▶ x_2 par 1
 - ▶ x_3 par 5
- ▶ Ajouter le tout
- ▶ Retrancher 10



Exemple 2

- ▶ Choisir un nombre x
- ▶ **Si** x est pair :
 - ▶ Diviser x par 2
- ▶ **Sinon** :
 - ▶ Multiplier x par 2
 - ▶ Ajouter 1
- ▶ Répéter 5 fois

La régression linéaire




La régression linéaire




$$\text{MSE} = \frac{1}{N} \sum_{i=1}^N (y_i - (ax_i + b))^2$$

La régression linéaire





$$\text{MSE} = 57,19$$



$$\text{MSE} = 19,19$$

La régression linéaire



<https://quentington.github.io/scripts/linear-regression>

Les paramètres optimaux

$$\min_{a,b} \frac{1}{N} \sum_{i=1}^N (y_i - (ax_i + b))^2$$

► On calcule $\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i$ et $\bar{y} = \frac{1}{N} \sum_{i=1}^N y_i$

Les paramètres optimaux

$$\min_{a,b} \frac{1}{N} \sum_{i=1}^N (y_i - (ax_i + b))^2$$

- ▶ On calcule $\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i$ et $\bar{y} = \frac{1}{N} \sum_{i=1}^N y_i$
- ▶ On calcule ensuite

$$a^* = \frac{\sum_{i=1}^N (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^N (x_i - \bar{x})^2} \quad \text{et} \quad b^* = \bar{y} - a^* \bar{x}$$

Les paramètres optimaux


$$\min_{a,b} \frac{1}{N} \sum_{i=1}^N (y_i - (ax_i + b))^2$$

- ▶ On calcule $\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i$ et $\bar{y} = \frac{1}{N} \sum_{i=1}^N y_i$
- ▶ On calcule ensuite


$$a^* = \frac{\sum_{i=1}^N (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^N (x_i - \bar{x})^2} \quad \text{et} \quad b^* = \bar{y} - a^* \bar{x}$$

- ▶ La meilleure droite est alors $y = a^*x + b^*$


L'importance du nombre de données




L'importance du nombre de données



L'importance du nombre de données




L'importance du nombre de données




L'importance du nombre de paramètres


- Plus il y a de paramètres, plus l'on peut décrire des formes complexes



Réseaux de neurones




Réseaux de neurones



$$\begin{aligned} h_1^{(1)} &= a_1^{(1)}x_1 + b_1^{(1)} \\ &\quad + a_2^{(1)}x_2 + b_2^{(1)} \\ &\quad + a_3^{(1)}x_3 + b_3^{(1)} \end{aligned}$$

Réseaux de neurones



$$\begin{aligned} h_1^{(1)} &= a_1^{(1)}x_1 + b_1^{(1)} \\ &+ a_2^{(1)}x_2 + b_2^{(1)} \\ &+ a_3^{(1)}x_3 + b_3^{(1)} \end{aligned}$$

► 6 paramètres **par**
neurone !

Réseaux de neurones : l'entraînement

- ▶ Il s'agit de trouver les "meilleurs" paramètres

Réseaux de neurones : l'entraînement

- ▶ Il s'agit de trouver les "meilleurs" paramètres
- ▶ Dans le cas de la régression linéaire, les meilleurs étaient ceux minimisant la MSE

Réseaux de neurones : l'entraînement

- ▶ Il s'agit de trouver les "meilleurs" paramètres
- ▶ Dans le cas de la régression linéaire, les meilleurs étaient ceux minimisant la MSE

Avant d'entraîner un réseau de neurone, il faut :

Réseaux de neurones : l'entraînement

- ▶ Il s'agit de trouver les "meilleurs" paramètres
- ▶ Dans le cas de la régression linéaire, les meilleurs étaient ceux minimisant la MSE

Avant d'entraîner un réseau de neurone, il faut :

1. Définir ce que l'on attend de notre réseau

Réseaux de neurones : l'entraînement

- ▶ Il s'agit de trouver les "meilleurs" paramètres
- ▶ Dans le cas de la régression linéaire, les meilleurs étaient ceux minimisant la MSE

Avant d'entraîner un réseau de neurone, il faut :

1. Définir ce que l'on attend de notre réseau
2. Trouver une **fonction de perte** pertinente

Exemples de fonctions de perte

$$\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

$$\frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

$$\begin{cases} \frac{1}{2}(y - \hat{y})^2 & \text{si } |y - \hat{y}| \leq \delta \\ \delta|y - \hat{y}| - \frac{1}{2}\delta^2 & \text{sinon} \end{cases}$$

$$-\frac{1}{n} \sum_{i=1}^n [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)]$$

$$-\sum_{i=1}^C y_i \log(\hat{y}_i)$$

$$-\alpha_t (1 - p_t)^\gamma \log(p_t)$$

$$\max(0, 1 - y \cdot \hat{y})$$

$$\max(0, \|f(A) - f(P)\|_2^2 - \|f(A) - f(N)\|_2^2 + \alpha)$$

$$Y \frac{1}{2} D^2 + (1 - Y) \frac{1}{2} \max(0, m - D)^2$$

$$\sum_x P(x) \log \left(\frac{P(x)}{Q(x)} \right)$$

$$1 - \frac{2 \sum y_i \hat{y}_i}{\sum y_i + \sum \hat{y}_i}$$


$$1 - \frac{\sum A_i B_i}{\sqrt{\sum A_i^2} \sqrt{\sum B_i^2}}$$

$$\sum_{i=1}^n \log(\cosh(\hat{y}_i - y_i))$$

$$\frac{1}{n} \sum_{i=1}^n (\log(y_i + 1) - \log(\hat{y}_i + 1))^2$$

$$\mathbb{E}_{\tilde{x}}[D(\tilde{x})] - \mathbb{E}_x[D(x)]$$

Modèles Génératifs



Grands Modèles de Langage (LLM)

Grands Modèles de Langage (LM)

Pour résumer

